Local Atlas / 端侧知识库

seekdb × 阶跃星辰 · 一页技术说明 · 2026-10-27

12th Gen Intel(R) Core(TM) i5-12450H；RAM 15.74 GiB；实际 WebGPU 适配器 intel gen-12lp；Chrome 156.0.0.0；WASM 4线程；seekdb 2G / CPU_COUNT=2。

模型与量化

BGE-small-zh-v1.5（BAAI，MIT），采用 Xenova 公开 ONNX 产物，固定版本 75c43b069aac4d136ba6bc1122f995fedcfd2781。FP16 权重转换；INT8 为 QInt8 / per-channel / reduce-range。每配置计入一个权重及六个公共文件：FP32 95,402,424 B，FP16 48,047,974 B（1.986 倍压缩），INT8 24,561,389 B（3.884 倍）。文件 SHA-256 和转换配方随源码提供。

端侧运行

Transformers.js 3.8.1 + ONNX Runtime Web，文档与问题均在浏览器 Worker 中计算；512 维 CLS/L2，中文问题前缀，220 字符分块/40 重叠。自动显式选择 WebGPU FP16；无适配器、缺少 shader-f16、初始化或首次预热失败则降级 WASM INT8，并显示原因。模型及运行时从本地站点加载，禁止远程模型加载，无云推理。Chrome/Edge 的正常 GPU 与实际禁用 GPU 两条路径均通过功能测试。

seekdb 与状态

seekdb-js 1.4.0 连接持久化本地 seekdb 1.4.0。每库独立集合：id、原文片段、VECTOR(512)、metadata；HNSW/cosine（m=16、ef_construction=200、ef_search=64）+ 中文 ngram(2) 全文索引。hybridSearch 在数据库完成两路召回与 RRF（60，窗口20），客户端只展示排序结果。完整原文也存于 seekdb。稳定内容 ID/upsert 保证重试幂等；写入后统一 refresh_index。writing / pending_refresh / ready 持久化，未完成库拒绝查询；模型版本/精度绑定集合，切库清空结果，全局串行保护 SDK 会话变量。

配置	模型 MB	文档/s	seekdb ms	E2E ms	Recall / nDCG @5
FP32 / WASM	95.40	45.17	10.21	77.30	0.9048 / 0.8696
FP16 / WebGPU	48.05	103.18	11.13	84.80	0.9048 / 0.8696
INT8 / WASM	24.56	23.33	10.03	103.61	0.9048 / 0.8696

优化与测量

模型/缓存复用、长度分桶、batch=8、批次统一刷新。固定 24 文档（4,686 B）、21 个标注问题；每配置导入3次、查询63次，中位数，保存全部记录。FP16 GPU 批量吞吐为 FP32 的 2.28 倍；固定 INT8/WASM 的 batch 1→8 吞吐增加 42.0%；仅改刷新策略，14,108.98→557.52 ms（下降 96.0%）。三种精度 Recall/nDCG 变化为0；单条查询延迟未获改善，如实报告。

首次加载/预热/缓存（ms）：FP32 1371/83/613；FP16 1604/871/1486；INT8 1527/53/583。

E2E 包含编码、网络、seekdb、真实结果 DOM 绘制等待。全部15次导入和315次查询原始记录见 results/benchmark.json；详细计时范围与测试限制见 results/REPORT.md；启动见 README.md。质量仅为工程微型集，不外推。

模型：huggingface.co/Xenova/bge-small-zh-v1.5（固定版本见上文）
SDK：github.com/oceanbase/seekdb-js | 官方比赛基线：d647275c